PROJET DE FIN D'ETUDE

Vision par ordinateur et apprentissage profond

Soutenance finale

Pierlouis Pillet, Adam Ramsis, Rodrick Zegang

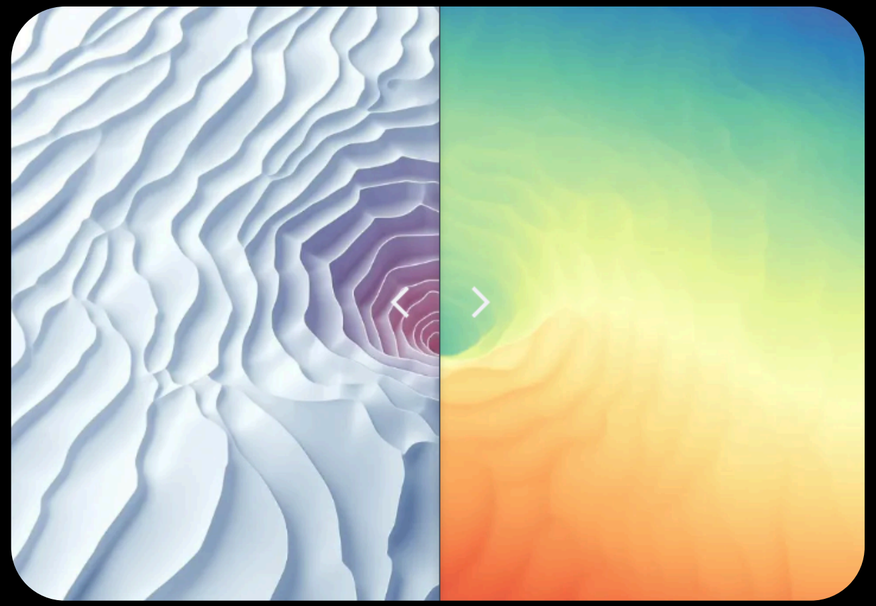

Sommaire

I. Problématique et motivation
II. Architecture
III. Création du modèle
IV. Impasse et évolution
V. Intégration du LLM
VI. Déploiement
VI. Démonstration
VII. Conclusion et perspectives

Problématique et motivation

Qu’est-ce que l'estimation de profondeur monoculaire ?
Pour quoi faire?

Autonomous car

3D Scan

3D modelisation of real environment without relying on expensive material

Creating 3D scene from image

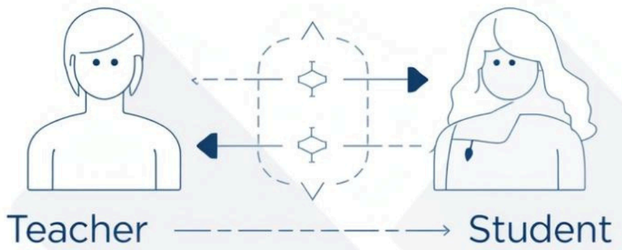

Pipeline Teacher-Student

Le modèle Depth Anything V2 utilise une **pipeline spécial** Teacher-Student pour générer des pseudo-labels, permettant ainsi un entraînement efficace et robuste sur des données synthétiques et réelles.

Architecture - Pipeline Teacher-Student

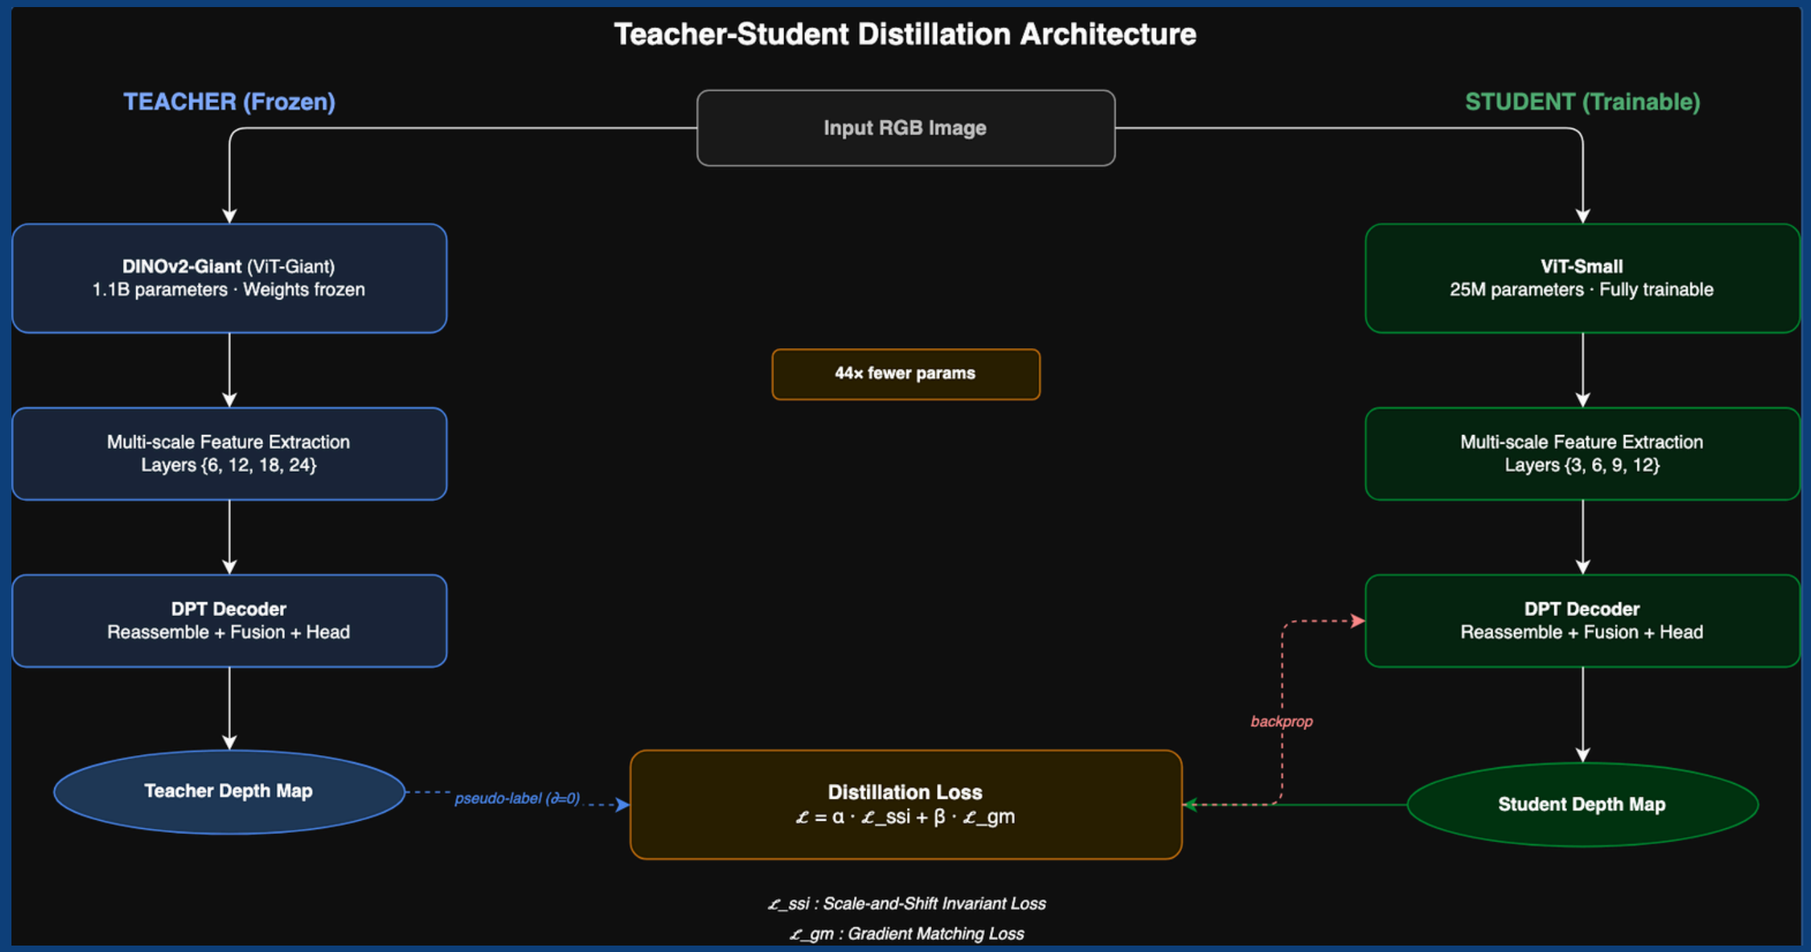

Creation du Modele - Training Dataset

- **Hypersim : 50 000 images, Synthetiques, Ground truth parfaite**

- **SA-1B : Non etiqueté, donnees reelles, Pseudo-labels Teacher**

- **V-KITTI2 : 2 682 images, synthetiques, scenes de conduite**

Données utilisées

Datasets synthétiques et réelles présentés

Hypersim Dataset

Le dataset Hypersim comprend environ 50 000 images synthétiques de haute qualité, fournissant une diversité de scènes et d'angles nécessaires pour entraîner des modèles de profondeur robustes.

Datasets réels

Les datasets réels, tels que SA-1B et LSUN, contiennent entre 50 000 et 500 000 images non étiquetées, permettant une vaste exploration des scènes complexes et variées pour l'entraînement en générant des pseudos labels.

Creation du Modele - 3 phases

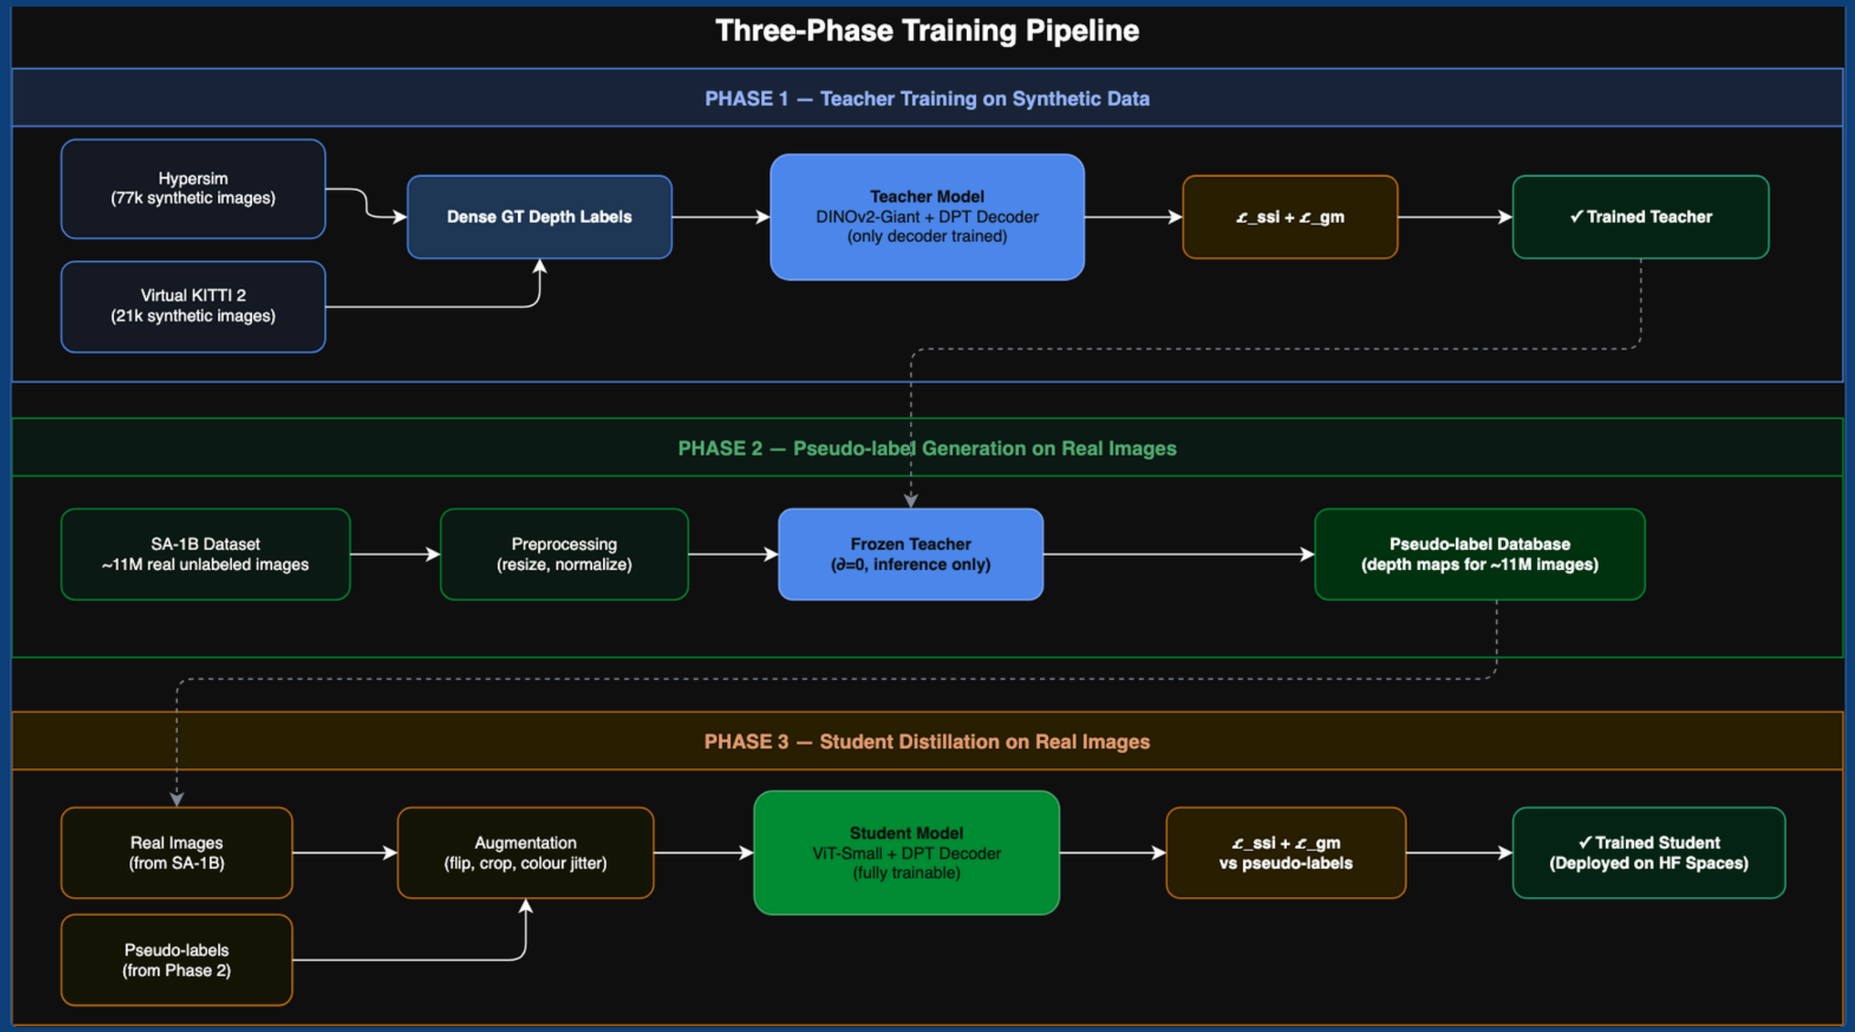

Architecture du modèle

DINOv2 et Dense Prediction Transformer

Encoder DINOv2

Le modèle DINOv2 se décline en plusieurs variantes, allant de Small à Giant, permettant une **flexibilité** dans les applications, tout en offrant une performance optimale pour l'estimation de profondeur.

Decoder DPT

Le Dense Prediction Transformer (DPT) est conçu pour traiter les sorties de l'encoder, en s'assurant que les détails fins sont capturés efficacement, ce qui est crucial pour des estimations précises.

Limitation et évolution

Limitation

Bugs divers

- Fusion DPT inversee
- L_gm non scale-invariant
- crop_size = 480, Pas multiple de 14 — desalignement patch ViT (14 × 35 = 490)

SLURM : TIME LIMIT

- Jobs annules apres 8h sur H100
- 30 epochs necessitent 20h+
- Jobs 2930, 2936, 2940 annules

Telechargement du dataset

- SA-1B : plusieurs heures de download avant de pouvoir lancer le premier job

Sans Mixed Precision (AMP)

- Temps d'entrainement × 2 avant l'integrationd'AMP sur le trainer

Limitation et évolution

Limitation

V1	V2	V3	V4
Baseline officiel Depth Anything V2	Premiere implementation custom — baseline experimental	Fix decoder + AMP + Teacher v3 + 512 lignes de tests	SLURM optimise Scheduler reset Minor fixes

Intégration du LLM

Application Web

Webcam → Depth model (HF Spaces) → Depth Map + Image → Groq API LLAMA 4 Scout → Réponse NL

Intégration du LLM

Interface

- Interface Bilingue
- Page projet scientifique style documentation technique + pdf reader papier scientifique
- Démo analyse et réponse en temps réel
- TTS + vibration mobile
- Chaud = proche / Froid = loin

Démonstration

Timeline des phases

Phase 1

Cadrage théorique, étude approfondie et premier test

Phase 2

Data engineering et préparation des datasets

Phase 3

Implémentation de l'architecture du modèle

Phase 4

Baseline et validation du modèle

Merci !